움직임 정보를 활용한 웨어러블 생체신호 기반 감정인식: IMU 인지형 게이트 잔차 융합

IMU-Aware Gated Residual Fusion for Emotion Recognition using Wearable Physiological Signals under Motion

요 약

웨어러블 생체신호 기반 감정인식은 사용자의 움직임에 따라 센싱되는 신호가 왜곡될 수 있어 인식 성능이 저하될 수 있다. 본 논문에서는 사용자의 움직임 정보(IMU)를 활용하여 생체신호 특징을 적응적으로 보정하는 IMU-Aware Gated Residual Fusion(IGRF) 모델을 제안한다. 제안 모델은 심전도(ECG), 피부전도도(EDA), 호흡신호(RSP)의 특성을 고려한 독립적인 CNN 인코더를 구성하고, 각 생체신호 특징과 IMU 특징을 고려해 시간축 보정값과 채널별 게이트를 생성한다. 이를 잔차 연결을 통해 기존 각 생체신호 특징에 반영함으로써 움직임 정보를 고려한 특징 추출을 수행한다. egoEMOTION 벤치마크 실험에서 제안 모델은 기존 기준 모델 대비 VAD 이진 분류의 F1-score를 7.3%p, 9종 감정 분류의 F1-score를 6.8%p 향상시킴을 확인하였다.

1. 서론

최근 인간의 감정을 인식하기 위해 영상, 표정, 동작 등의 외적 정보뿐만 아니라, 감정 변화에 따른 생리적 반응을 반영하는 생체신호를 입력으로 활용한 연구가 활발히 진행되고 있다[1,2]. 특히 심전도(ECG), 피부전도도(EDA), 호흡신호(RSP)는 감정 상태를 분석하는 유용한 정보를 제공하지만, 웨어러블 센서를 통해 측정되는 특성상 사용자의 움직임에 의한 신호 왜곡이 발생하여 감정인식 성능이 저하될 수 있다.

본 논문에서는 이를 개선하기 위하여 움직임을 반영하여 분석 특징을 개선하는 IMU-Aware Gated Residual Fusion (IGRF) 구조를 제안한다. 제안 방법은 ECG, EDA, RSP별 독립적인 CNN 인코더를 통해 특징을 추출하고, IMU로 측정한 움직임 정보를 활용하여 각 생체신호 특징을 적응적으로 보정한다. 제안 모델의 유효성을 검증하기 위해 egoEMOTION 벤치마크[1]의 VAD 이진 분류 및 9종 감정 분류 과제에서 기존 모델과 성능을 비교하였으며, 제안 모델은 기존 기준 모델 대비 VAD 이진 분류의 F1-score를 7.3%p, 9종 감정 분류의 F1-score를 6.8%p 향상시킴을 확인하였다. 이를 통해 움직임 정보를 생체신호 특징에 적응적으로 반영하는 IMU 기반 게이트 잔차 융합이 감정인식 성능 향상에 기여할 수 있음을 확인하였다.

2. 제안방법

본 장에서는 제안하는 신경망 구조를 상세히 소개한다. 전체적인 신경망 구조는 생체신호 입력에 기반한 감정인식 목적에 맞추어 구성하였다. 그림 1은 본 논문이 제안하는 전체 구조이며, 각 생체신호(ECG, EDA, RSP) 분석을 위해 분리된 형태의 인코더(2.1절)를 가지는 것이 특징이다. IMU로 측정한 사용자의 움직임 정보를 이용하여 생체신호 특징을 보정하는 IMU

인지형 게이트 잔차 융합(IMU-Aware Gated Residual Fusion, IGRF) 모듈(2.2절)은 각 생체신호 인코더의 첫 번째 CNN 블록 뒤에 적용된다.

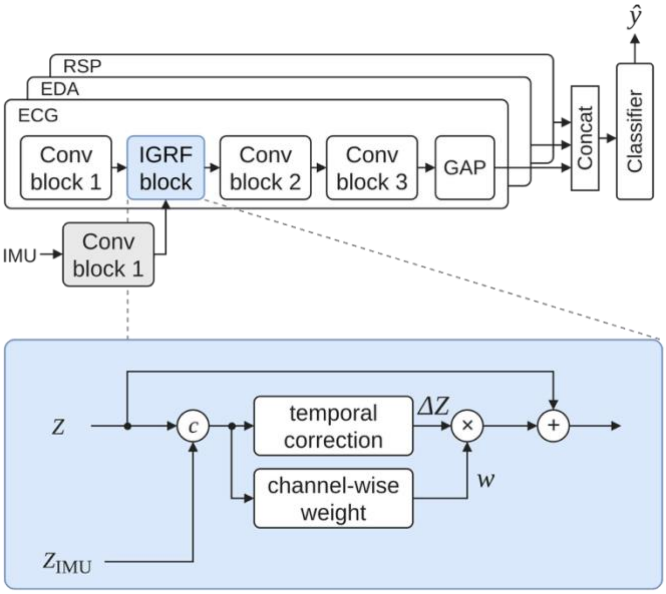


그림 1. 제안 네트워크 구조

표 1. 생체신호별 CNN 인코더의 세부 설정

신호	커널 크기	Stride	Padding
ECG	16, 8, 8	2/2, 2/1, 1/1	8, 4, 4
EDA	8, 8, 4	2/2, 2/1, 1/1	4, 4, 2
RSP	16, 16, 8	2/2, 2/2, 1/1	8, 8, 4

2.1 생체신호별 독립적 특징 추출을 위한 다중 임베딩

ECG, EDA, RSP는 서로 다른 생리적 반응을 측정하므로 신호별 파형과 시간적 변화 특성에 차이가 있다. 이를 고려하여 Multi-Input DCNN(MI-DCNN)[3]의 기본 구조를 바탕으로 각 생체신호에 독립적인 인코더를 구성한다. 각 인코더는 가중치를 공유하지 않으며, Conv–ReLU–Conv–ReLU–BN–MaxPooling으로 이루어진 3개의 블록으로 구성된다. 기존 MI-DCNN의 CNN 블록 구성을 유지하되, 각 생체신호 인코더의 커널 크기, 출력 채널 수 및 stride를 사전 실험을 통해 조정하였으며, 세부 설정은 표 1에 제시한다. 각 칸의 숫자는 CNN 블록 1, 2, 3에 해당하는 설정이며, 한 블록에 존재하는 두 CNN 층의 설정은 stride의 경우만 상이하여 별도 표기하였다.

2.2 IMU 인지형 게이트 잔차 융합

사용자의 움직임 정보가 미치는 영향을 생체신호 임베딩 과정에 반영하기 위해 사용자가 착용한 스마트 글라스의 IMU 값을 참고하여 생체신호 특징의 잔차를 구해 반영하는 IMU-Aware Gated Residual Fusion (IGRF)을 제안한다. 먼저 MI-DCNN 인코더의 첫 번째 CNN 블록에서 초기 특징 ($Z_{1,phys}$)을 추출하고, IMU 역시 별도의 CNN 블록을 통해 움직임 특징 (Z_{IMU})를 추출한다. 이후 각 생체신호 특징을 IMU 특징과 개별적으로 결합하여 모달리티별 게이트 잔차 보정을 수행한다. 뒤따르는 IGRF 블록에서는 생체신호 특징과 IMU 특징을 연결한 정보(Z_{phys}^{IMU})를 이용하여 두 가지 값을 구하게 된다. 첫 번째는 1개의 CNN층(H_{phys}^{C})과 tanh 함수를 통해 시간축 보정값 ΔZ를, 두 번째는 1개 CNN층 (H_{phys}^{G}) 및 sigmoid 함수를 통해 ΔZ의 채널별 반영 가중치 w_{phys} 를 추정한다. 이를 활용하여 두 요소의 곱을 기존 생체신호 특징에 더하여 다음과 같이 보정된 특징($\hat{Z}_{1,phys}$) 을 계산한다. 아래 수식은 이러한 과정을 정리한 수식이다.

$$Z_{phys}^{IMU} = Concat(Z_{1,phys}, Z_{IMU})$$
$$\Delta Z_{phys} = \tanh(H_{phys}^{C}(Z_{phys}^{IMU}))$$
$$w_{phys} = \sigma(H_{phys}^{G}(Z_{phys}^{IMU}))$$
$$\hat{Z}_{1,phys} = Z_{1,phys} + \Delta Z_{phys} \odot w_{phys}$$

이후 보정된 특징은 각 MI-DCNN의 나머지 블록을 통과한다. 최종적으로는 각 모달리티에서 추출된 특징들을 전역 평균 풀링을 거친 후 연결하여 최종 분류기를 통해 감정 분류를 수행한다. 이후 분류층의 출력과 정답 레이블로 교차 엔트로피 손실을 계산한 뒤 이를 줄이도록 파라미터를 갱신하여 최적의 모델을 학습한다.

3. 실험

3.1 데이터셋 및 실험 설정

본 연구에서는 웨어러블 생체신호 기반 감정인식 성능을 평가하기 위해 egoEMOTION [1] 데이터셋을 활용한다. 해당 데이터셋은 43명의 참가자가 감정 유도 영상을 시청하는 Session A와 다양한 일상 활동을 수행하는 Session B로 구성되며, 각 참가자는 웨어러블 센서 및 스마트 글라스를 착용하고 각 session을 수행한다. 본 연구에서는 90Hz로 정리된 ECG, EDA, RSP 및 IMU 신호를 사용하여 Valence, Arousal, Dominance를 각각 High/Low로 분류하는 VAD 이진 분류 태스크와 9종 감정 분류 태스크를 수행한다.

제안 방법의 성능을 검증하기 위해 egoEMOTION에서 제시한 기존 생체신호 입력 DCNN, 본 논문에서 최적화한 MI-DCNN, 그리고 제안하는 MI-

표 2. egoEMOTION 벤치마크에서 제공한 VAD 이진 분류 및 Emotion 분류 실험 결과

네트워크	VAD		Emotion
	F1-score	BAC	Macro-F1
DCNN[1]	0.623	0.532	0.122
MI-DCNN[3]	0.693	0.561	0.159
IGRF(ours)	**0.696**	**0.573**	**0.190**

DCNN+IGRF를 비교한다. 모든 모델은 동일한 데이터 분할 및 학습 조건에서 평가하며, VAD 분류에는 평균 F1-score와 Balanced Accuracy(BAC)를, 9종 감정 분류에는 Macro-F1을 평가 지표로 사용한다. 객관적인

검증을 위해 전체 실험은 5-fold cross-validation을 사용하여 진행한다.

3.2 감정인식 성능 비교

표 2는 egoEMOTION 데이터셋에서 감정인식 성능을 비교한 결과를 나타낸다. 제안 모델은 기존 egoEMOTION 베이스라인 DCNN 모델과 비교하여 VAD F1-score는 62.3%에서 69.6%, BAC는 53.2%에서 57.3%로 성능이 향상되었고, 9종 감정 분류 Macro-F1은 12.2%에서 19.0%로 향상된 결과를 확인하였다. 즉, 기준 모델 대비 VAD는 F1-score 7.3%p, BAC 4.1%p 개선되었고, 9종 감정 분류는 6.8%p 개선되었다.

보다 자세하게는, 먼저 기준 모델에 MI-DCNN을 적용했을 때의 VAD 분류 F1-score는 기준 DCNN 모델 대비 7%p 향상된 69.3%, BAC는 2.9%p 향상된 56.1%로 나타났다. 9종 감정 분류 Macro-F1 또한 15.9%로 3.7%p 향상됨을 확인하였다. 이는 각 생체신호에 본 논문에서 최적화한 독립적인 인코더를 적용하였을 때 두 분류 과제 모두 성능이 개선됨을 보여준다. 특히 VAD 분류 과제에서 큰 폭으로 성능이 개선되었다.

이후 본 논문에서 제안하는 MI-DCNN에 IGRF를 적용한 모델의 VAD 분류 F1-score는 69.6%, BAC는 57.3%로 나타났다. MI-DCNN과 비교하면 0.3%p, 1.2%p 향상된 결과가 확인된다. 한편, 9종 감정 분류에서는 Macro-F1이 19%로 MI-DCNN보다 3.1%p의 뚜렷한 향상을 확인할 수 있다. 결과적으로 IMU 특징, 즉 사용자의 움직임을 생체 분석 개선의 잔차 정보로 활용한 제안 모델이 감정인식의 전반적인 성능을 향상시킨 것을 확인할 수 있다.

4. 결론 및 향후 연구

본 논문에서는 웨어러블 생체신호 기반 감정인식에서 사용자의 움직임에 따른 영향을 고려하기 위해 IMU-Aware Gated Residual Fusion(IGRF) 모델을 제안하였다. 제안 모델은 MI-DCNN을 기반으로 ECG, EDA, RSP별 독립적인 CNN 인코더를 구성하고, IMU 특징을 활용한 게이트 잔차 융합을 통해 생체신호 특징을 적응적으로 보정한다. egoEMOTION 벤치마크의 VAD 이진 분류 및 9종 감정 분류 실험을 통해 기존 모델 대비 감정인식 성능 향상을 확인하였다.

본 논문에서 제안하는 신경망은 생체신호 분석이 핵심이 되도록 IMU 기반 융합 정보를 생체신호 특징 개선을 위한 잔차 형태로 구성한 것이 특징이며, 적은 연산량으로 구현하였기 때문에 다양한 형태의 생체신호 기반 감정인식에 활용 가능할 것으로 사료된다. 향후에는 움직임 강도에 따른 모델의 강건성을 추가로 검증하고, 다양한 웨어러블 환경으로 연구를 확장할 예정이다.

참고문헌

[1] M. Jammot et al., "egoEMOTION: Egocentric vision and physiological signals for emotion and personality recognition in real-world tasks," Adv. Neural Inf. Process. Syst. (NeurIPS), vol. 38, 2025.

[2] D. H. Hagos et al., "Deep temporal modeling and ensemble fusion for multimodal emotion recognition from physiological signals," in Proc. 17th ACM Int. Conf. Bioinformatics, Comput. Biol. Health Inform. (BCB), 2026.

[3] P. Chen et al., "An improved multi-input deep convolutional neural network for automatic emotion recognition," Front. Neurosci., vol. 16, Art. no. 965871, 2022.